خلاصه‌ی مقاله‌ی ۰۲: Short-Term Load Forecasting for AI-Data Center

- **نویسندگان:** Chen، Li، Mughees و Li (دانشگاه آلبرتا، کانادا)
- **انتشار:** پذیرفته‌شده در IEEE PES General Meeting 2025 — arXiv:2503.07756 (۵ صفحه)
- **فایل در آرشیو:** `docs/papers/02_alberta_ai_datacenter_stlf_2503.07756.pdf`
- **سطح:** عمیق (baseline اصلی پروژه)
- **منبع این خلاصه:** متن کامل مقاله. موارد نامشخص با ⚠️ علامت خورده‌اند.

---

۱. در یک پاراگراف

نویسندگان می‌گویند دیتاسنترهای هوش مصنوعی نوسان‌های سریع و بزرگ توان دارند که برای شبکه مشکل‌ساز است، و مدل‌سازی صریح این بار سخت است چون الگوریتم‌های در حال اجرا «جعبه‌ی سیاه»اند. پس یک گردش‌کار داده‌محور سه‌مرحله‌ای پیشنهاد می‌کنند (جمع‌آوری و پیش‌پردازش → آموزش مدل → پیش‌بینی و کاربرد) و آن را با سه شبکه‌ی عمیق (GRU، LSTM و 1D-CNN) روی **داده‌ی MIT Supercloud** آزمایش می‌کنند. هر سه مدل به R^2 حدود ۰٫۹۶ می‌رسند و LSTM کمی بهتر است، ولی هر سه در **جهش‌ها و افت‌های ناگهانی عقب می‌مانند.**

---

۲. مفاهیم کلیدی

تعریف مسئله

- ورودی: **H** مقدار گذشته‌ی بار، $X(t-H)$ تا $X(t-1)$.
- خروجی: دنباله‌ای از مقادیر آینده تا **P** گام جلوتر (پیش‌بینی چندگامی، یعنی کل مسیر آینده یک‌جا پیش‌بینی می‌شود).
- تابع هزینه: **MSE** میانگین‌گیری‌شده روی کل افق.

داده و پیش‌پردازش (مهم‌ترین بخش برای ما)

مورد	مقدار در مقاله
داده	MIT Supercloud، فوریه تا اکتبر ۲۰۲۱
اوج توان تجمیعی	**۴۵ کیلووات** روی ۴۴۸ GPU
تجمیع	توان بر اساس job و نود جمع زده شده تا «کل توان کشیده‌شده از شبکه‌ی توزیع محلی» را نشان دهد
دقت زمانی	**۱ ثانیه**
پنجره‌ی ورودی	**۳۰۰ گام** (۵ دقیقه)
افق پیش‌بینی	**۹۰ ثانیه** (۹۰ گام)
نرمال‌سازی	Min-Max
تقسیم داده	**۷۰/۱۵/۱۵** برای آموزش، اعتبارسنجی و آزمون

مدل‌ها

- **LSTM** (با لایه‌ی خروجی تمام‌متصل LSTM یعنی ،FC_LSTM در جدول با اسم)
- **GRU** (با گیت‌های کمتر LSTM نسخه‌ی ساده‌تر)
- **1D-CNN** (کانولوشن یک‌بعدی روی محور زمان)

نتایج (جدول I مقاله)

مدل	RMSE	MAE	MBD	sMAPE	R^2
LSTM	**0.5624**	**0.2916**	0.0319	**2.2557**	**0.9639**
GRU	0.5668	0.3163	−0.0433	2.6288	0.9634
1D-CNN	0.5789	0.3172	0.1216	2.5014	0.9618

- **MBD** (میانگین انحراف سوگیری): مثبت یعنی مدل بیش‌برآورد می‌کند، منفی یعنی کم‌برآورد. GRU 1 کمی کم‌برآورد، 1D-CNN بیشتر بیش‌برآورد.
- **مشاهده‌ی کیفی نویسندگان:** در بزرگ‌نمایی ۱ دقیقه‌ای پیش‌بینی نزدیک به واقعیت است، ولی در **افت‌ها و جهش‌های ناگهانی الگو را (lag) نمی‌گیرد**؛ در بزرگ‌نمایی ۱۰ دقیقه‌ای **پیش‌بینی نسبت به مقدار واقعی عقب می‌ماند**؛ در بازه‌ی ۱ ساعته در دوره‌های پرنوسان انحراف دارد.

بحث کاربردی

- کنترل اولیه‌ی فرکانس شبکه ۲ تا ۱۰ ثانیه و کنترل ثانویه (AGC) ۱۰ تا ۳۰ ثانیه زمان پاسخ دارد؛ نویسندگان می‌گویند افق ۹۰ ثانیه برای این کاربردها کافی است.
- پیشنهاد استفاده از پیش‌بینی برای **باتری (BESS)** و peak shaving، ولی **بدون پیاده‌سازی**. این دقیقاً همان خلأیی است که RQ4 پروژه‌ی ما پر می‌کند.

---

۳. نقاط ضعف (فرصت‌های پروژه‌ی ما)

1. **هیچ مدل مرجع ساده‌ای ندارد.** نه Naive (پیش‌بینی = آخرین مقدار)، نه ARIMA. این **مهم‌ترین ضعف** است: در گام یک‌ثانیه‌ای، توان در ۹۰ ثانیه معمولاً خیلی تغییر نمی‌کند، و ممکن است یک مدل Naive هم R^2 نزدیک ۰٫۹۶ بگیرد. بدون این مقایسه معلوم نیست LSTM واقعاً چیزی یاد گرفته یا نه.
2. **تفاوت مدل‌ها بسیار کوچک است** (R^2 بین ۰٫۹۶۱۸ و ۰٫۹۶۳۹) و **فقط یک اجرا** گزارش شده: نه چند seed، نه انحراف معیار، نه آزمون معنی‌داری. پس «LSTM بهترین است» از نظر آماری ثابت نشده. آزمون Diebold-Mariano و سه seed در پروتکل ما همین را درست می‌کند.
3. **جزئیات بازتولید ناقص است:** ⚠ تعداد لایه‌ها، نورون‌ها، learning rate، epoch و optimizer گزارش نشده؛ کد منتشر نشده.
4. **واحد معیارها نامشخص است:** ⚠ معلوم نیست RMSE=0.56 به کیلووات است یا روی داده‌ی نرمال‌شده. همچنین معلوم نیست معیارها میانگین کل ۹۰ گام‌اند یا فقط یک گام خاص.
5. **نرمال‌سازی:** ⚠ نگفته‌اند Min-Max فقط روی داده‌ی آموزش fit شده یا روی کل داده (اگر دومی، نشت اطلاعات دارد).
6. **ضعف در جهش‌ها را خودشان می‌پذیرند ولی اندازه‌گیری نمی‌کنند.** هیچ معیار جداگانه‌ای برای خطا در بازه‌های جهش ندارند. معیار «MAE در بازه‌های جهش» پروتکل ما دقیقاً همین خلأ را پر می‌کند.
7. **ادعای LLM بزرگ‌تر از داده است.** مقدمه از آموزش مدل‌های زبانی بزرگ حرف می‌زند، ولی داده‌ی MIT عمدتاً شبکه‌های بینایی (ResNet، VGG، U-Net) و BERT کوچک است.
8. **بدون عدم قطعیت:** فقط پیش‌بینی نقطه‌ای؛ هیچ بازه‌ی اطمینانی ندارد (خلأ RQ3).

---

۴. ⚠ یک نکته‌ی بسیار مهم برای پروتکل پروژه

تنظیمات این مقاله با «تصمیم‌های ثابت» سند پروژه‌ی ما **فرق دارد:**

	مورد	مقاله‌ی آلبرتا	پروتکل ما
دقت زمانی	۱ ثانیه	۱ دقیقه	
پنجره‌ی ورودی	۳۰۰ گام (۵ دقیقه)	۶۰ گام (۶۰ دقیقه)	
افق	۹۰ ثانیه	۱، ۵ و ۱۵ دقیقه	

نتیجه: عدد R^2 برابر ۰٫۹۶۴ آن‌ها **مستقیماً با نتایج ما قابل مقایسه نیست.** در سند پروژه آمده که هفته‌ی ۳ LSTM را «با تنظیمات مقاله‌ی آلبرتا» پیاده کنیم و اعداد را مقایسه کنیم؛ برای اینکه این کار معنادار باشد، دو راه هست:

- **راه الف:** یک آزمایش بازتولید جدا با تنظیمات خودشان (۱ ثانیه، ۳۰۰ ورودی، ۹۰ خروجی) روی یک زیرمجموعه‌ی کوچک، **به‌علاوه‌ی مدل Naive**. اگر Naive هم نزدیک ۰٫۹۶ بگیرد، این خودش یک یافته‌ی جالب برای مقاله است.
- **راه ب:** فقط در پروتکل خودمان کار کنیم و در مقاله صریح بنویسیم که تنظیمات فرق دارد.

پیشنهادم راه الف است، ولی این تصمیم را **در جلسه‌ی ۱ با استاد** مطرح کن.

داده‌ی یک‌ثانیه‌ای برای ۸ ماه حدود ۲۰ میلیون نقطه است، پس بازتولید کامل سنگین است؛ زیرمجموعه کافی است.

---

۵. سؤال‌هایی که ممکن است استاد بپرسد

- **«مدل تو از مقاله‌ی آلبرتا بهتر است؟»** → مقایسه‌ی مستقیم اعداد معتبر نیست چون دقت زمانی، پنجره و افق فرق دارد؛ برای همین یا بازتولید تحت تنظیمات خودشان انجام می‌دهیم یا تفاوت را صریح گزارش می‌کنیم.
- **«R^2 برابر ۰٫۹۶ خیلی خوب است؛ دیگر چه چیزی برای بهبود مانده؟»** → سه چیز: (۱) معلوم نیست این عدد از یک مدل Naive بهتر است، (۲) خطا در جهش‌ها که مهم‌ترین لحظه‌ها برای شبکه‌اند اندازه‌گیری نشده، (۳) عدم قطعیت و ارزش کنترلی بررسی نشده.
- **«چرا دقت یک دقیقه، وقتی آلبرتا یک ثانیه گرفته؟»** → افق‌های چنددقیقه‌ای به کنترل باتری و برنامه‌ریزی ذخیره‌ساز مربوط‌اند؛ هزینه‌ی محاسباتی مدل‌های کوانتومی روی سری یک‌ثانیه‌ای غیرعملی است؛ یک‌ثانیه را می‌توان به‌عنوان آزمایش تکمیلی داشت. (این استدلال را در جلسه با استاد تأیید کن.)

---

۶. برای نگاه با چشم خودت (حدود ۱۰ دقیقه)

1. **جدول I** (نتایج): اعداد را ببین و به این فکر کن که تفاوت‌ها چقدر کوچک‌اند.
2. **شکل ۴** (تقسیم داده): ببین دوره‌ی آزمون کدام بخش از سال است و آیا رفتارش با دوره‌ی آموزش فرق دارد.
3. **شکل‌های ۶ و ۷** (بزرگ‌نمایی ۱ و ۱۰ دقیقه): عقب‌ماندن پیش‌بینی از جهش‌ها را با چشم ببین؛ این همان مسئله‌ای است که پروژه‌ی ما روی آن تمرکز دارد.
4. **بخش III-A** (یک پاراگراف): تنظیمات داده و پیش‌پردازش.

---

۷. بلوک انگلیسی برای `docs/literature.md`

این را زیر عنوان `## 2. Short-Term Load Forecasting for AI-Data Center` جایگزین قالب خالی کن:

```markdown
```

Idea: AI-centric datacenters exhibit fast, large power fluctuations that chall

Method: MIT Supercloud GPU power (Feb–Oct 2021, 448 V100 GPUs, aggregated peak

Results: LSTM best on all metrics: RMSE 0.5624, MAE 0.2916, sMAPE 2.26%, R^2 0.

Weaknesses / Notes for this project:
- No naive/persistence or statistical baseline — at 1 s resolution a persistence m
- Single run, no seeds, no variance, no significance testing; differences between
- Missing reproducibility details: architecture sizes, epochs, optimizer, learning
- Metric units (kW vs. normalized) and whether metrics are averaged over the 90-st
- Ramp/spike error is acknowledged qualitatively but not measured — our ramp-speci
- No uncertainty quantification (our RQ3) and no implemented control application (
- Settings differ from our protocol (1 s / 300 / 90 s vs. 1 min / 60 / 1-5-15 min)
- Intro frames the problem around LLM training, but the MIT workload is mostly vis