خلاصه‌ی مقاله‌ی ۰۴: Better than classical? The subtle art of benchmarking quantum machine learning models

- **نویسندگان:** Joseph Bowles، Shahnawaz Ahmed، Maria Schuld (شرکت Xanadu، سازنده‌ی PennyLane؛ و دانشگاه Chalmers)
- **انتشار:** arXiv:2403.07059 (مارس ۲۰۲۴)
- **فایل در آرشیو:** `docs/papers/04_bowles_benchmarking_qml_2403.07059.pdf`
- **سطح:** عمیق (قواعد مقایسه‌ی منصفانه برای RQ2)
- **کد و داده:** https://github.com/XanaduAI/qml-benchmarks
- **منبع این خلاصه:** متن کامل مقاله.

---

۱. در یک پاراگراف

نویسندگان می‌پرسند آیا ادعاهای رایج «مدل کوانتومی از کلاسیک بهتر است» قابل اعتمادند. اول نشان می‌دهند در ادبیات چنین ادعاهایی غالب است، بعد توضیح می‌دهند چرا benchmark به‌شدت به طراحی آزمایش حساس است و چطور «سوگیری مثبت» می‌تواند نتیجه را برعکس کند. سپس خودشان یک benchmark بزرگ و منصفانه اجرا می‌کنند: **۱۲ مدل کوانتومی** معروف (انتخاب‌شده با روشی تصادفی و بی‌طرف) روی **۱۶۰ دیتاست** طبقه‌بندی دودویی، در مقابل مدل‌های کلاسیک ساده و «آماده». نتیجه: **مدل‌های کلاسیک ساده به‌طور سیستماتیک بهترند**، و **حذف درهم‌تنیدگی از مدل‌های کوانتومی اغلب عملکرد را بدتر نمی‌کند.** پیام اصلی مقاله این است که benchmark باید برای یادگرفتن «چه چیزی در مدل مهم است» طراحی شود، نه برای اعلام برنده.

---

۲. مفاهیم کلیدی

تصویر ادبیات: سوگیری آشکار

- از ۵۵ مقاله‌ی arXiv تا دسامبر ۲۰۲۳ که عبارت «quantum machine learning» و «outperform» را داشتند، حدود ۴۰٪ ادعا کرده‌اند مدل کوانتومی از کلاسیک بهتر است و حدود ۵۰٪ ادعای بهبود یک روش کوانتومی را دارند.
- فقط **۳ مقاله (۴٪)** گزارش کرده‌اند که مدل کوانتومی بهتر نبوده، و دوتایش هم تقصیر را گردن نویز سخت‌افزار انداخته‌اند.

سه خطر benchmark (بخش I)

1. **انتخاب داده:** تغییرات کوچک در دیتاست یا حذف چند دیتاست از مجموعه می‌تواند رتبه‌بندی را کاملاً عوض کند («قرعه‌کشی benchmark»). شکل ۲ مقاله نشان می‌دهد همان مدل کوانتومی با جابه‌جایی جزئی داده از دقت ۰٫۵۳ به ۱٫۰۰ می‌رسد.
2. **بقیه‌ی طراحی آزمایش:** تنظیم ابرپارامتر گسترده می‌تواند یک مدل پایه را هم‌سطح مدل‌های پیشرفته کند؛ انتخاب معیار ارزیابی هم نتیجه را عوض می‌کند.
3. **سوگیری مثبت:** آزمایش ذهنی مقاله: ۱۰۰ پژوهشگر، هر کدام ۲۰ مدل کوانتومی امتحان می‌کنند و فقط بهترینش را در برابر یک مدل کلاسیک منتشر می‌کنند. حتی اگر در واقعیت میانگین کلاسیک ۰٫۶۵ و کوانتومی ۰٫۵۵ باشد، میانگین منتشرشده‌ی کوانتومی ۰٫۷۴ در برابر ۰٫۶۵ کلاسیک می‌شود؛ **یعنی نتیجه برعکس می‌شود**، بدون هیچ تقلبی.

جمله‌ی کلیدی مقاله: سؤال «آیا مدل کوانتومی من از یادگیری ماشین کلاسیک بهتر است؟» با آزمایش عددی قابل پاسخ نیست؛ ولی سؤالی مثل «آیا عملکرد یک مدل روی یک مسئله‌ی مشخص با تغییر داده یا شرایط آموزش تغییر می‌کند؟» قابل پاسخ است.

طراحی آزمایش خودشان

مورد	مقدار
مدل‌های کوانتومی	۱۲ مدل در سه خانواده: شبکه‌های عصبی کوانتومی (۷)، روش‌های کرنل کوانتومی (۳)، شبکه‌های کانولوشنی کوانتومی (۲)
انتخاب مدل‌ها	از ۳۵۰۰ مقاله ← ۵۶۱ مقاله‌ی پرارجاع ← ۲۹ مناسب ← نمونه‌ی **تصادفی** ۱۵ ← ۱۱ قابل پیاده‌سازی
مدل‌های کلاسیک	MLP، SVM با کرنل گاوسی، CNN ساده؛ عمداً «آماده» و نه پیشرفته
داده	۶ روش تولید داده‌ی مصنوعی ← ۱۰ ← ۱۶۰ benchmark ← **دیتاست** طبقه‌بندی دودویی
تنظیم ابرپارامتر	جست‌وجوی شبکه‌ای کامل با اعتبارسنجی متقابل ۵ بخشی، **برای همه‌ی مدل‌ها**
ابزار	PennyLane + JAX + scikit-learn
بیشترین اندازه	۱۸ کیوبیت؛ سقف ۲۴ ساعت برای هر اعتبارسنجی ۵ بخشی روی ۱۰ هسته

نکته‌ی بحث‌برانگیز: مدل کلاسیک هم‌اندازه

نویسندگان **صریحاً** می‌گویند تطبیق تعداد پارامتر بین مدل کوانتومی و کلاسیک را در زمینه‌ی خودشان **معنادار نمی‌دانند**، چون نقش پارامترها در معماری‌های مختلف فرق دارد (همان‌طور که کسی تعداد پارامتر یک روش کرنل و یک شبکه‌ی عصبی را برابر نمی‌کند). به‌جایش هر خانواده‌ی کوانتومی را با معادل کلاسیک طبیعی‌اش مقایسه کرده‌اند. ⚠ این مستقیماً به پروتکل ما مربوط است؛ بخش ۴ را ببین.

نتایج اصلی (بخش V)

1. **مدل‌های کلاسیک آماده به‌طور سیستماتیک بهترند.** در هر سه خانواده، مدل کلاسیک اول شد. رتبه‌بندی‌ها بین benchmarkهای مختلف به‌طرز شگفت‌انگیزی ثابت بود.
2. **مدل‌های هیبریدی شبیه میزبان کلاسیکشان رفتار می‌کنند.** بهترین مدل کوانتومی، **DressedQuantumCircuitClassifier** بود: یک شبکه‌ی عصبی کلاسیک ← مدار کوانتومی ← شبکه‌ی عصبی کلاسیک. عملکردش تقریباً دنبال MLP بود؛ در ۴ از ۷ MLP، benchmark اول و این مدل دوم بود، و در ۳ تای دیگر برعکس.
3. **مدل‌های بدون درهم‌تنیدگی خوب کار می‌کنند.** نسخه‌های کاملاً جداپذیر (بدون گیت درهم‌تنیده، قابل شبیه‌سازی با یک کیوبیت) هم‌سطح یا بهتر از بیشتر مدل‌های کوانتومی بودند. حذف درهم‌تنیدگی از DressedQuantumCircuit **هیچ افتی** نداشت؛ فقط در DataReuploading و تا حدی Quantum Boltzmann Machine افت دیده شد.
4. **بیش‌برازش سیستماتیک یا اثر مقیاس دیده نشد.** با سخت‌تر شدن مسئله، مدل‌های کوانتومی نسبت به کلاسیک بهتر نشدند.
5. **مدل‌های مبتنی بر amplitude encoding** بدترین‌ها بودند.
6. **شگفتی:** تقریباً همه‌ی مدل‌های کوانتومی روی **ساده‌ترین** مسئله (داده‌ی جداپذیر خطی) بد عمل کردند. توضیح احتمالی: angle embedding مرزهای تصمیم **تناوبی** می‌سازد که با مرز خطی در ابعاد بالا جور نیست.

یافته‌های تنظیم ابرپارامتر (بخش IV)

- دقت یک مدل بسته به ابرپارامتر می‌تواند از **حدس تصادفی تا تقریباً کامل** تغییر کند.
- بهترین تعداد لایه به دیتاست بستگی دارد؛ در یک benchmark لایه‌ی بیشتر بهتر است، در دیگری بدتر.

- **مقیاس داده‌ی ورودی** مهم است؛ پیش‌فرض آن‌ها بازه‌ی $[-\pi/2, \pi/2]$ برای angle embedding بود، ولی گاهی مقیاس کوچک‌تر بهتر بود.

پنج سؤال طراحی (بخش VI)

1. آیا بخش کوانتومی در مدل‌های هیبریدی واقعاً کمک می‌کند، یا فقط «ضرری نمی‌زند»؟ (آزمایش: جایگزینی مدار با یک لایه‌ی کلاسیک هم‌معماری نتیجه‌ی کیفی مشابه داد.)
2. چه چیزی data re-uploading را موفق می‌کند؟ (ablation: **مقیاس‌دهی آموزش‌پذیر ورودی** و **embedding آموزش‌پذیر** هر دو حیاتی‌اند؛ تابع هزینه‌ی خاص مهم نیست.)
3. کرنل‌های کوانتومی چه معیار فاصله‌ای تعریف می‌کنند؟ (در ۲ بعد شبیه کرنل گاوسی‌اند.)
4. چرا ویژگی‌های چندجمله‌ای (amplitude encoding) کار نمی‌کنند؟
5. چرا مدل‌های کوانتومی با داده‌ی جداپذیر خطی مشکل دارند؟

توصیه‌ی نهایی

«حذف کوانتومی بودن» از مدل (مثلاً حذف درهم‌تنیدگی) باید آزمایش استاندارد هر benchmark باشد. روش‌های دیگر: محدودکردن به گیت‌های Clifford یا شبیه‌سازی MPS با bond dimension پایین.

---

۳. محدودیت‌های این مقاله (برای اینکه اغراق نکنی)

- **فقط طبقه‌بندی دودویی**، نه رگرسیون و نه سری زمانی. نتایج مستقیماً به مسئله‌ی ما منتقل نمی‌شوند.
- **داده‌ی عمدتاً مصنوعی و کوچک.** خودشان می‌گویند نتایج روی داده‌ی کوچک را نمی‌شود به داده‌ی بزرگ تعمیم داد.
- مدل‌ها «پایه‌ای و تأثیرگذار» انتخاب شده‌اند، نه بهترین و جدیدترین.
- همه روی شبیه‌ساز، بدون نویز.

پس جمله‌ی درست در پایان‌نامه: «Bowles و همکاران در یک benchmark گسترده‌ی طبقه‌بندی نشان دادند...»، نه «ثابت شده که مدل‌های کوانتومی بدترند.»

---

۴. پیامدها برای پروژه‌ی ما (مهم)

الف) معماری QCNN ما همان «Dressed Quantum Circuit» است

مدل هیبریدی ما (encoder خطی → مدار → decoder خطی) دقیقاً از خانواده‌ی بهترین مدل این مقاله است. **پیش‌بینی منطقی:** عملکردش به مدل کلاسیک میزبان نزدیک خواهد بود و احتمالاً حذف درهم‌تنیدگی اثر زیادی ندارد. این را از الان بدان تا نتیجه غافلگیرت نکند؛ و اگر نتیجه‌ی ما چیز دیگری نشان داد، آن خودش یافته‌ی جالبی است.

ب) ⚠ تنش با «مدل کنترل هم‌اندازه» در پروتکل ما

سند پروژه تصمیم گرفته هر مدل کوانتومی با یک مدل کلاسیک **هم‌تعداد پارامتر** مقایسه شود؛ Bowles صریحاً این را معنادار نمی‌داند. پیشنهاد من برای حل این تنش (در جلسه‌ی ۱ با استاد مطرح کن):

- **هر دو مقایسه را نگه داریم، با دو هدف متفاوت:**

1. **مقایسه با مدل‌های کلاسیک قوی و آماده** (LightGBM، LSTM) با تنظیم ابرپارامتر برابر → جواب سؤال «آیا رقابتی است؟» (سبک Bowles).

2. **مقایسه با مدل کنترل هم‌معماری** (همان encoder و decoder، با یک لایه‌ی کلاسیک به‌جای مدار) ← جواب سؤال «آیا خود مدار چیزی اضافه می‌کند؟». این دقیقاً آزمایش بخش VI.A مقاله است، پس با روح Bowles سازگار است. تعداد پارامتر را **گزارش** کن، ولی آن را تنها معیار نکن.

- و **ablation در هم‌تنیدگی** طبق توصیه‌ی نهایی مقاله.

ج) بودجه‌ی برابر تنظیم ابرپارامتر

اگر برای مدل کوانتومی ۲۰ پیکربندی امتحان کنی و برای LSTM فقط ۲ تا، همان سوگیری مثبت آزمایش ذهنی مقاله را ساخته‌ای. **برای همه‌ی مدل‌ها یک بودجه‌ی مشخص و برابر** (مثلاً تعداد آزمایش Optuna) تعیین و گزارش کن.

د) همه‌ی نسخه‌های امتحان‌شده را ثبت کن

هر نسخه‌ی مدل کوانتومی که امتحان می‌کنی (حتی ناموفق) باید در W&B ثبت شود و در مقاله به تعدادشان اشاره شود. این جلوی سوگیری انتخاب را می‌گیرد، و قانون شماره‌ی ۱ پروژه هم همین است.

هـ) نکته‌های فنی برای پیاده‌سازی

- **با مقیاس‌دهی آموزش‌پذیر ورودی** بهترین عملکرد را بین مدل‌های کوانتومی خالص داشت؛ ارزش دارد **data re-uploading** ما امتحان شود. QCNN به‌عنوان یک نسخه از
- **مقیاس ورودی مدار** را به‌عنوان ابرپارامتر در نظر بگیر ($[-\pi/2, \pi/2]$ بازه‌ی) (به‌عنوان نقطه‌ی شروع).
- از **amplitude encoding** دوری کن.
- هزینه‌ی محاسباتی واقعی است: حتی با خوشه‌ی ۱۰ هسته‌ای، یک دیتاست برای مدل‌های تک‌رقمی کیوبیت بیش از یک روز طول کشیده. epoch در سند پروژه را تأیید می‌کند. این حد ۱۰ دقیقه‌ای

و) چارچوب‌بندی سؤال پژوهشی

به‌جای «آیا مدل کوانتومی بهتر است؟» بپرس «**آیا عملکرد مدل هیبریدی با کاهش داده‌ی آموزشی یا تعداد کیوبیت تغییر می‌کند، و این تغییر با مدل کلاسیک متناظر چه فرقی دارد؟**» آزمایش‌های کسر داده و تعداد کیوبیت در هفته‌ی ۶ دقیقاً همین شکل‌اند و از نظر روش‌شناسی قابل‌دفاع‌ترند.

---

۵. سؤال‌هایی که ممکن است استاد بپرسد

- «**اگر Bowles نشان داده کلاسیک بهتر است، چرا اصلاً کوانتوم را امتحان می‌کنی؟**» ← مقاله‌ی Bowles فقط طبقه‌بندی روی داده‌ی مصنوعی کوچک است؛ سری زمانی و رگرسیون روی داده‌ی واقعی بررسی نشده. هدف ما هم اعلام برنده نیست، بلکه یک ارزیابی منصفانه در یک کاربرد جدید است، که خود Bowles آن را توصیه می‌کند.
- «**چرا مقایسه با مدل هم‌اندازه، وقتی Bowles مخالف آن است؟**» ← دو مقایسه‌ی جدا با دو هدف؛ مدل هم‌معماری برای سنجیدن نقش خود مدار است، که همان آزمایش بخش VI.A مقاله است.
- «**اگر مدل کوانتومی بدون درهم‌تنیدگی هم همان‌قدر خوب کار کرد، چه نتیجه‌ای می‌گیری؟**» ← اینکه در این مسئله «کوانتومی بودن» عامل عملکرد نیست؛ این یک یافته‌ی قابل‌انتشار و هم‌راستا با Bowles و Cerezo است.

---

۶. برای نگاه با چشم خودت (حدود ۱۰ دقیقه)

1. **شکل ۳** (آزمایش ذهنی سوگیری مثبت): ساده‌ترین و قوی‌ترین استدلال مقاله؛ در دفاع به کارت می‌آید.
2. **شکل ۱۰** (رتبه‌بندی کل مدل‌ها): ببین مدل‌های کلاسیک کجا قرار دارند.

3. **شکل ۱۳** (ablation در هم‌تنیدگی): ببین DressedQuantumCircuit بدون در هم‌تنیدگی افتی ندارد.
4. **بند «Classical models» در بخش II.B.4** (یک پاراگراف): استدلال‌شان علیه مدل هم‌اندازه.

---

۷. بلوک انگلیسی برای `docs/literature.md`

این را زیر عنوان `## 4. Better than classical? (Bowles et al.)` جایگزین قالب خالی کن:

```markdown
**Idea:** Benchmarks in QML are highly sensitive to experimental design and subjec

**Method:** 12 influential QML models (quantum neural networks, quantum kernels, c

**Results:** Out-of-the-box classical models systematically outperform the quantum

**Weaknesses / Notes for this project:**
- Scope limited to binary classification on small synthetic data; no regression or
- Authors explicitly reject parameter-matched classical baselines as not meaningfu
- Our hybrid QCNN belongs to the dressed-circuit family: expect performance close
- Adopt: equal hyperparameter budget across all models; log every quantum variant
- Frame RQ2 as "how does performance change with training-data fraction and qubit
```