خلاصه‌ی مقاله‌ی ۰۶: A Physics-Aware Framework for Short-Term GPU Power Forecasting of AI Data Centers

- **نویسندگان:** Abu-Rub، Bayhan، Chawla، AlShaikh Saleh و Ghrayeb (دانشگاه حمد بن خلیفه، قطر)
- **انتشار:** arXiv:2605.04074 (آوریل ۲۰۲۶)؛ نسخه‌ای هم در کتابخانه‌ی دیجیتال ACM منتشر شده (DOI: 10.1145/3770855.3818033)
- **کد:** نویسندگان می‌گویند کد را منتشر کرده‌اند ⚠ (لینک مخزن را از PDF پیدا کن)
- **فایل در آرشیو:** `docs/papers/06_physics_aware_gpu_power_2605.04074.pdf`
- **سطح:** کامل — **نزدیک‌ترین کار قبلی به پروژه‌ی ما**
- **منبع این خلاصه:** متن مقاله تا بخش ۳.۳ (جدول نتایج کامل و بخش‌های throttling و ablation را نخواندم؛ موارد مربوط با ⚠ مشخص‌اند).

---

۱. در یک پاراگراف

نویسندگان روی **همان داده‌ی MIT Supercloud** و **با همان دقت یک‌دقیقه‌ای پروژه‌ی ما** توان GPU را ۵ تا ۸۰ دقیقه جلوتر پیش‌بینی می‌کنند. اول ۱۶ مدل پیشرفته (عمدتاً ترنسفورمرها) را مقایسه می‌کنند و می‌بینند مدل‌های **خطی ساده مثل DLinear از بیشتر ترنسفورمرها بهترند.** بعد بهترین مدل (DLinear) را با یک **قید فیزیکی** تقویت می‌کنند: یک مدل حرارتی RC دوگرهی (GPU و حافظه) که رابطه‌ی توان و دما را با قانون سرمایش نیوتن توصیف می‌کند، به‌علاوه‌ی یک قید «throttling». مدل حاصل، **PI-DLinear**، از همه‌ی مدل‌های مقایسه‌شده دقیق‌تر است و در رخدادهای throttling و گذارهای ناگهانی رفتار فیزیکی معقول‌تری دارد.

---

۲. مفاهیم کلیدی

داده (⚠️ بسیار مهم: اعداد سند پروژه‌ی ما از همین‌جا آمده‌اند)

مورد	مقدار
داده	MIT Supercloud، فوریه تا اکتبر ۲۰۲۱
اوج توان تجمیعی	۴۵ کیلووات روی ۴۴۸ GPU
دقت زمانی	**۱ دقیقه**
تعداد گام	**حدود ۳۳۰،۵۰۰**
مدت	**حدود ۲۳۸ روز**
متغیر های اولیه	۷: utilization GPU، utilization حافظه، حافظه‌ی آزاد، حافظه‌ی مصرفی، دمای GPU، دمای حافظه، توان
متغیر های نهایی	۵ (حافظه‌ی آزاد و مصرفی به‌خاطر همبستگی کم حذف شدند)
نرمال‌سازی	Min-Max **فقط بر اساس داده‌ی آموزش** ✅
تجمیع	بر اساس job و نود، برای نشان‌دادن کل توان کشیده‌شده از شبکه‌ی توزیع محلی

این دقیقاً همان اعدادی است که در بخش ۷-۱ سند پروژه‌ی ما آمده. یعنی **این مقاله مستقیم‌ترین نقطه‌ی مقایسه‌ی ماست**، خیلی بیشتر از مقاله‌ی آلبرتا که دقت یک‌ثانیه‌ای داشت.

تنظیمات آزمایش

- **پنجره‌ی ورودی:** ۲۴۰، ۳۶۰، ۴۸۰ و ۶۰۰ دقیقه (۴ تا ۱۰ ساعت). ⚠️ خیلی بلندتر از ۶۰ دقیقه‌ی پروتکل ما.
- **افق:** ۵، ۱۰، ۲۰، ۴۰ و ۸۰ دقیقه.
- **ورودی چندمتغیره:** گذشته‌ی هر پنج متغیر، خروجی فقط توان.
- **۵ seed**؛ می‌گویند انحراف معیار بین اجراها ناچیز بود.

۱۶ مدل مقایسه‌شده (از کتابخانه‌ی TSLib)

Transformer، iTransformer، TimeXer، TiDE، TSMixer، Reformer، PatchTST، Nonstationary Transformer، LightTS، FiLM، FEDformer، Pyraformer، Crossformer، **DLinear**، **NLinear**، **Linear**.

یافته‌ی جانبی مهم: مدل‌های **خطی ساده** (DLinear) به‌طور واضح از اکثر ترنسفورمرها بهتر بودند. این با یافته‌ی معروف Zeng و همکاران (۲۰۲۳) هم‌خوان است که مدل‌های خطی ساده در بسیاری از مسائل سری زمانی ترنسفورمرها را شکست می‌دهند.

DLinear چیست؟

سری ورودی را با میانگین متحرک به دو بخش **روند** و **باقی‌مانده** تجزیه می‌کند، روی هر کدام **یک لایه‌ی خطی** می‌گذارد و خروجی‌ها را جمع می‌کند. بسیار ساده، سریع و کم‌پارامتر.

قید فیزیکی: مدل حرارتی RC

- ایده: GPU تقریباً ۹۹٪ **انرژی الکتریکی را به گرما** تبدیل می‌کند. پس توان و دما با یک معادله‌ی دیفرانسیل به هم مربوط‌اند.
- مدل: **دو گره‌ی حرارتی** (GPU و حافظه)، هر کدام با یک «خازن حرارتی» C و «مقاومت حرارتی» R به محیط و به هم — دقیقاً شبیه یک مدار RC الکتریکی (برای تو به‌عنوان مهندس برق آشنا!).
- معادله‌ی گره‌ی GPU: `C_g · dT_g/dt = α·P − (T_g − T_a)/R_ga − (T_g − T_m)/R_gm`
- با حل برای P و مشتق‌گیری، یک **قید روی نرخ تغییر توان (dP/dt)** بر حسب مشتقات دما به دست می‌آید که در تابع هزینه به‌عنوان جریمه اضافه می‌شود.
- پارامترهای R و C با **حداقل مربعات بازگشتی (RLS)** روی داده‌ی آموزش تخمین زده و ثابت شده‌اند. دمای محیط چون در داده نبود، ثابت ۲۷ **درجه** فرض شده.

قید throttling

- مشاهده‌ی جالب از داده‌ی MIT: افت‌های ناگهانی توان (بیش از ۱۵٪) با **utilization بالای پایدار** همبسته‌اند، نه با دمای بحرانی (دمای GPU هیچ‌وقت به حد ۸۰ تا ۹۰ درجه نرسیده).
- قید: اگر utilization بالای ~۹۰٪ باشد، توان پیش‌بینی‌شده نباید بالا برود.

تابع هزینه

`L = λ_u·L_data + λ_r·L_physics + λ_θ·L_throttle`، با وزن‌های خودتطبیق.

نتایج

- **MSE**، ۰٫۹۹ **تا ۵۲٪** از همه‌ی مدل‌ها بهتر است. بهبود (میانگین روی همه‌ی پنجره‌ها و افق‌ها): ۰٫۷۸ **تا ۳۹٪ در** PI-DLinear **RMSE**. تا ۲۲٪ **در** ۰٫۳۷، **MAE در**
- با بلندتر شدن پنجره‌ی ورودی پایدار می‌ماند PI-DLinear خطای.
- مثلاً در یک گذار) ساده کمتر است DLinear و گذار ناگهانی، خطا نسبت به throttling در مثال‌های رخداد MAE ۲٫۵۱ از (به ۱٫۴۷).
- ⚠ اعداد جدول روی داده‌ی **نرمال‌شده**‌اند (مثلاً MAE برای ۰٫۱۵ حدود iTransformer)، نه کیلووات.

---

۳. نقاط ضعف (فرصت‌های پروژه‌ی ما)

1. **مدل مرجع ساده‌ی Naive یا آماری ندیدم.** ⚠ در بخش‌هایی که خواندم، مقایسه فقط با مدل‌های عمیق TSLib بود؛ نه Naive، نه ARIMA، نه LightGBM، نه LSTM. اگر در بخش‌های بعدی هم نبود، این همان ضعف مقاله‌ی آلبرتاست.
2. **بازه‌ی بهبود بسیار گسترده** (از کمتر از ۱٪ تا ۵۲٪): یعنی در برابر قوی‌ترین رقبا بهبود کوچک است؛ عدد ۵۲٪ احتمالاً در برابر ضعیف‌ترین ترنسفورمر است. بدون آزمون معنی‌داری.
3. **مدل حرارتی روی داده‌ی تجمیعی ۴۴۸ GPU:** یک «گره‌ی GPU» واحد برای میانگین دمای صدها کارت در نودهای مختلف، از نظر فیزیکی یک ساده‌سازی شدید است. عدد R و C به‌دست‌آمده بیشتر پارامتر برازش است تا ویژگی فیزیکی.
4. **دمای محیط ثابت فرض شده.**

5. **بدون عدم قطعیت** (فقط پیش‌بینی نقطه‌ای).
6. **بدون معیار مخصوص جهش**؛ فقط چند مثال کیفی از رخدادهای throttling و گذار. ⚠ (بخش ۳.۵ درباره‌ی تشخیص throttling هست که کامل نخواندم.)
7. **بدون کاربرد کنترلی** و بدون مدل‌های پایه‌ی zero-shot مثل Chronos و TimesFM.

---

۴. پیامدها برای پروژه‌ی ما (مهم)

الف) این مقاله باید مرجع مقایسه‌ی اصلی ما در بخش Related Work باشد

همان داده، همان دقت زمانی، افق‌های هم‌پوشان (۵ دقیقه مشترک است؛ ۱۵ ما بین ۱۰ و ۲۰ آن‌هاست). **مقایسه با این مقاله معتبرتر از مقایسه با آلبرتاست.** اگر کدشان در دسترس است، حتی می‌شود PI-DLinear را در جدول بنچمارک خودمان اجرا کرد.

ب) DLinear و NLinear را به بنچمارک RQ1 اضافه کن

مدل‌های خطی سبک، سریع و قوی‌اند و روی همین داده بهترین نتیجه را داده‌اند. نبودنشان در جدول ما یک خلأ آشکار خواهد بود. کتابخانه‌ی `neuralforecast` که در پشته‌ی ابزار ماست هر دو را دارد. ⚠ این یک تغییر در لیست مدل‌های اسپرینت ۲ است؛ در جلسه‌ی ۱ مطرح کن.

ج) پنجره‌ی ورودی ۶۰ دقیقه را دوباره بررسی کن

آن‌ها ۴ تا ۱۰ ساعت تاریخچه استفاده کرده‌اند. پنجره‌ی ۶۰ دقیقه‌ای ما برای مدل‌های کوانتومی (که ورودی کوچک می‌خواهند) منطقی است، ولی برای مدل‌های کلاسیک ممکن است اطلاعات مفید را دور بریزد. **نمودار ACF در هفته‌ی ۲** باید این را روشن کند. یک راه میانه: پنجره‌ی ۶۰ برای مقایسه‌ی اصلی، و یک آزمایش جانبی با پنجره‌ی بلندتر برای بهترین مدل‌های کلاسیک.

د) ایده‌هایی برای ویژگی‌سازی

- **دما متغیر کمکی ارزشمندی است**، چون با تأخیر از توان پیروی می‌کند (رابطه‌ی RC)، پس اطلاعات گذشته‌ی توان را در خودش انباشته دارد.
- **utilization بالای پایدار** پیش‌نشانگر افت ناگهانی (throttling) است. یک ویژگی مثل «تعداد دقیقه‌های اخیر با utilization بالای ۹۰٪» می‌تواند به LightGBM کمک کند.

هـ) جایگاه نوآوری ما در برابر این مقاله

آن‌ها: دقت بالاتر با تزریق فیزیک. ما: (۱) بنچمارک کامل‌تر شامل مدل‌های ساده، آماری، LightGBM و مدل‌های پایه، (۲) معیارهای کمّی جهش، (۳) مدل‌های کوانتومی-کلاسیک، (۴) عدم قطعیت کالیبره، (۵) ارزش کنترلی. **هیچ‌کدام از این پنج مورد در این مقاله نیست.**

و) یک ارتباط جالب با رشته‌ی تو

مدل حرارتی RC دقیقاً همان مدار RC درس مدار است، فقط با دما به‌جای ولتاژ و توان حرارتی به‌جای جریان. اگر بعداً خواستی یک «تکمیلی» به پروژه اضافه کنی که دانش برق-کنترل را نشان بدهد، استفاده از این مدل RC به‌عنوان یک قید یا ویژگی کاندید خوبی است.

---

۵. سؤال‌هایی که ممکن است استاد بپرسد

- **«کار قبلی روی همین داده چه کرده و تو چه چیزی اضافه می‌کنی؟»** → PI-DLinear در دقت یک‌دقیقه‌ای، فیزیک حرارتی را به DLinear اضافه کرده؛ ما بنچمارک گسترده‌تر با مدل‌های ساده و پایه، معیار جهش، مدل کوانتومی، عدم قطعیت و کاربرد کنترلی اضافه می‌کنیم.
- **«چرا DLinear در جدول تو نیست؟»** → باید باشد؛ اضافه‌اش می‌کنیم.

- **«چرا پنجره‌ی ۶۰ دقیقه، وقتی کار قبلی ۴ تا ۱۰ ساعت گرفته؟»** → محدودیت ورودی مدل‌های کوانتومی و یکسان‌بودن پروتکل برای همه؛ با آزمایش جانبی پنجره‌ی بلندتر اثرش را گزارش می‌کنیم.

---

۶. برای نگاه با چشم خودت (حدود ۱۰ دقیقه)

1. **جدول ۱** (خلاصه‌ی داده): همان اعداد سند پروژه‌ی ما.
2. **جدول ۲** (نتایج همه‌ی مدل‌ها): ببین فاصله‌ی DLinear با ترنسفورمرها چقدر است، و دنبال مدل Naive یا LSTM بگرد.
3. **شکل ۱** (سه رخداد throttling و گذار).
4. **شکل ۳** (رابطه‌ی توان با utilization و دما).
5. لینک کد را در PDF پیدا کن و در یادداشت‌هایت بنویس.

---

۷. بلوک انگلیسی برای `docs/literature.md`

این را به‌عنوان بخش ۶ (یا زیر عنوان مناسب) در فایل اضافه کن:

markdown

```
## 6. A Physics-Aware Framework for Short-Term GPU Power Forecasting of AI Data Ce

**Link:** https://arxiv.org/abs/2605.04074 (also ACM DL, DOI 10.1145/3770855.38180

**Idea:** Pure deep models can produce physically inconsistent forecasts and degra

**Method:** MIT Supercloud aggregated GPU power at **1-minute** resolution (~330.5

**Results:** Lightweight linear models outperform most transformers. PI-DLinear is

**Weaknesses / Notes for this project:**
- **Closest prior work**: same dataset and same 1-min resolution as our protocol (
- No naive/statistical/GBM/LSTM baselines seen in the sections read (verify in ful
- Lumped RC model applied to aggregated temperatures of 448 GPUs is a strong simpl
- No uncertainty quantification, no ramp-specific metrics, no foundation models, n
- Action items: add DLinear/NLinear to our RQ1 benchmark; revisit the 60-min look-
```