خلاصه‌ی مقاله ۷: Kaseb و همکاران، «Quantum neural networks for power flow analysis»

مشخصات: Kaseb, Möller, Tosti Balducci, Palensky, Vergara. *Electric Power Systems Research*, vol. 235, 110677, اکتبر ۲۰۲۴ (ویژه‌نامه‌ی PSCC 2024). دسترسی آزاد، CC BY 4.0. DOI: 10.1016/j.epsr.2024.110677

منبع این خلاصه: متن کامل نسخه‌ی ژورنالی (ScienceDirect). فصل ۴ رساله مقایسه نشده است. نکته‌های بررسی‌نشده با ⚠ مشخص شده‌اند.

---

۱. خلاصه در یک پاراگراف

مقاله اولین بررسی «سیستماتیک» شبکه‌های عصبی کوانتومی برای **تحلیل پخش بار (power flow)** است، نه پیش‌بینی سری زمانی. ورودی مدل توان اکتیو و راکتیو باس‌ها (p, q) و خروجی دامنه و زاویه‌ی ولتاژ (v, δ) است. برچسب‌ها از روش نیوتن-رافسون (NR) می‌آیند، پس شبکه نقش **مدل جانشین (surrogate)** دارد. سه مدل مقایسه شده‌اند: شبکه‌ی کلاسیک (NN)، شبکه‌ی کوانتومی خالص (QNN) و شبکه‌ی هیبریدی (QCNN) که مدار کوانتومی بین لایه‌های کلاسیک قرار دارد. آزمایش‌ها روی سیستم ۴ باسه (اصلی) و ۳۳ باسه (تکمیلی) و فقط روی شبیه‌ساز Qiskit Aer انجام شده است. نتیجه: با ۱۲۸ نمونه‌ی آموزشی نویزی، QCNN بهترین عملکرد را دارد و QNN هم از NN بهتر است. نویسندگان خودشان می‌گویند اجرا روی سخت‌افزار NISQ امروز عملی نیست و «ارزش افزوده نیاز به بررسی بیشتر دارد».

---

۲. مفاهیم کلیدی

معماری‌ها

- **QNN خالص:** feature map (ZFeatureMap: لایه‌ی Hadamard و سپس Rz در بازه‌ی `arctan(x)` با زاویه‌ی $[-\pi/2, \pi/2]$) ← ansatz (RealAmplitudes: Ry، CNOT، Ry) ← بازنگاشت Z اندازه‌گیری ← روی هر کیوبیت. خطی خروجی $[-1, 1]$ به بازه‌ی فیزیکی δ در $[-8, 8]$ (در $[0.85, 1.15]$ و v).
- **QCNN هیبریدی:** لایه‌ی کلاسیک ← (encoder) مدار کوانتومی ← لایه‌ی کلاسیک (decoder). شبیه autoencoder است. مزیت: تعداد کیوبیت به اندازه‌ی ورودی/خروجی وابسته نیست.
- **تعداد پارامتر کوانتومی:** ansatz دارای $n \times 4$ (استنتاج خودم از متن ⚠) می‌شود ۱۲ برابر ۶ کیوبیت برای پارامتر است.

تنظیمات آزمایش

- ۵۱۲ نمونه از استخر ۵۰۰۰تایی؛ تقسیم ۲۵٪ آموزش، ۲۵٪ اعتبارسنجی، ۵۰٪ آزمون، پس ۱۲۸ **نمونه‌ی آموزشی** (عمداً کم).
- داده‌ها مصنوعی‌اند: برای هر باس، توزیع نرمال حول بار پایه با انحراف معیار ۳۰٪.
- ۱۰۰۰ MSE، Adam، epoch، فعال‌ساز ReLU.
- ۶ کیوبیت برای QCNN (از جاروب ۱ تا ۷ کیوبیت).
- ۱۰۲۴ shot (انتخاب‌شده چون خطا نسبت به statevector از این تعداد به بعد ثابت می‌شود).
- شبیه‌سازی نویز سخت‌افزار (خطای اندازه‌گیری، گیت ناقص، amplitude damping، depolarizing) از ۰ تا ۱۰٪، روی QNN.

- نویز روی داده‌ی آموزش: ۱ تا ۱۰٪.
- NN: ۷ لایه‌ی مخفی، lr برابر 1.5e-4، weight decay برابر 3e-3، dropout صفر، batch size برابر ۱۶. این‌ها با تحلیل حساسیت روی عمق (۲ تا ۸ لایه)، lr، wd و dropout (۰ تا ۲٪) انتخاب شده‌اند.
- مدل مرجع ساده: رگرسیون خطی (LR).

پنج معیار مقایسه ۱. تعمیم‌پذیری (MSE آزمون) ۲. مقاومت در برابر نویز در داده‌ی آموزش ۳. حجم داده‌ی لازم ۴. خطای آموزش ۵. پایداری آموزش

نتایج اصلی (سیستم ۴ باسه، ۱۲۸ نمونه)

معیار	QNN نسبت به NN	QCNN نسبت به NN
MSE آزمون	۴۱٪ کمتر	۵۲٪ کمتر
MSE آموزش پس از ۱۰۰۰ epoch	۴۸٪ کمتر	۵۴٪ کمتر
میانگین MSE آموزش در طول epochها	۳۹٪ کمتر	۴۵٪ کمتر
انحراف معیار MSE آموزش	۲۵٪ کمتر	۳۴٪ کمتر

- **بدتر است**، حدود **۴ برابر داده** لازم دارد **QCNN** برای رسیدن به سطحی که **هنوز از** NN.
- تا حدود دو برابر بدتر می‌شود NN با افزایش نویز، عملکرد.
- برابر QNN برابر 0.00267 و QCNN، برابر NN 0.144، برابر LR 0.885: در جدول ۲، خطای میانگین ولتاژ 0.0061 (p.u.).
- برابر NN برابر 0.011 و برای QCNN برای MSE در سیستم ۳۳ باسه و شرایط حدی (اضافه‌ولتاژ و افت‌ولتاژ): بیشینه‌ی 0.032 است.

---

۳. ضعف‌ها

1. **داده‌ی مصنوعی و ساده:** نمونه‌های نرمال مستقل، بدون ساختار زمانی. نتیجه‌ها به سری زمانی خودهمبسته با جهش منتقل نمی‌شوند.
2. **مقیاس کوچک:** ۴ باس، ۱۲۸ نمونه، فقط شبیه‌ساز. مقاله خودش می‌گوید با نویز فعلی سخت‌افزار اجرا عملی نیست، ولی چکیده از «NISQ و FTQ» صحبت می‌کند.
3. **تنظیم نابرابر:** تحلیل حساسیت عمیق فقط برای NN شرح داده شده است. برای QCNN فقط تعداد کیوبیت و shot تنظیم شده و lr و بودجه‌ی جست‌وجوی آن گزارش نشده ⚠.
4. **ضعیف‌بودن احتمالی baseline:** NN با lr حدود 1e-4 و batch size برابر ۱۶ روی ۱۲۸ نمونه، با ۷ لایه، احتمالاً کم‌آموزش یا بیش‌برازش است. خود LR هم خطای بسیار بالا دارد (0.885).
5. **سوگیری ساختاری:** خروجی QNN/QCNN با بازنگاشت به بازه‌ی فیزیکی کران‌دار می‌شود. معلوم نیست NN هم همین محدودسازی خروجی را داشته است یا نه ⚠. اگر نداشته باشد، بخشی از مزیت می‌تواند از همین prior باشد، نه از مدار.
6. **کنترل هم‌اندازه گزارش نشده است:** تعداد پارامترهای NN و QCNN مقایسه نشده. معلوم نیست مدار کوانتومی جای یک لایه‌ی کلاسیک را می‌گیرد یا به آن اضافه می‌شود ⚠. «همان تعداد لایه‌ی کلاسیک» در متن مبهم است.

7. **بدون تکرار آماری:** در متن مقاله از چند seed، بازه‌ی اطمینان یا آزمون معناداری صحبتی نشده ⚠️. درصدها از یک اجرا هستند.
8. **تفسیر «پایداری آموزش»:** انحراف معیار loss در طول epochها اندازه‌گیری شده، نه تغییرپذیری بین seedها. نویسندگان تفاوت را به روش گرادیان (backprop در برابر parameter-shift) نسبت می‌دهند.
9. **نبود ablation درهم‌تنیدگی:** معلوم نیست مزیت از entanglement است یا از بازنگاشت زاویه‌ای و ساختار encoder/decoder (مقایسه با Bowles و Cerezo).
10. **داده‌ی مقاله در دسترس نیست:** «Data will be made available on request».

---

۴. پیام برای پروژه‌ی ما

آنچه عیناً برمی‌داریم

- ساختار sandwich: encoder خطی ← مدار ← decoder خطی. این برای ورودی ۶۰ گامی ضروری است، چون ۶۰ ورودی را نمی‌شود مستقیم روی ۴ تا ۸ کیوبیت گذاشت.
- جاروب تعداد کیوبیت (آنها ۱ تا ۷، ما ۲، ۴، ۶، ۸).
- بررسی همگرایی shot و انتخاب ۱۰۲۴.
- جاروب نویز سخت‌افزاری ۰ تا ۱۰٪.
- آزمایش حجم داده (آنها ۴ برابر داده برای NN؛ ما ۱٪، ۵٪، ۲۰٪، ۱۰۰٪).
- نگاشت پنج معیار به آزمایش‌های ما:

معیار Kaseb	معادل در پروژه
تعمیم‌پذیری	MAE/RMSE آزمون و MAE در جهش‌ها
مقاومت در برابر نویز	نویز shot و مدل نویز سخت‌افزار؛ اختیاری: نویز تزریق‌شده به ورودی آموزش
حجم داده	کسر داده ۱٪ تا ۱۰۰٪
خطای آموزش	منحنی loss آموزش
پایداری آموزش	انحراف معیار بین ۳ seed (قوی‌تر از تعریف مقاله)

آنچه عمداً متفاوت می‌کنیم

- **درهم‌تنیدگی:** مقاله ندارد، ما داریم **ablation**.
- **کنترل هم‌اندازه:** همان encoder و decoder با یک لایه‌ی کلاسیک کوچک به‌جای مدار. این رخنه‌ی نکته‌ی ۶ را می‌بندد.
- **بودجه‌ی tuning برابر:** برای همه‌ی مدل‌ها و ثبت همه‌ی اجراها (نکته‌ی ۳).
- **DM test و seed چند** (نکته‌ی ۷).
- **baseline قوی:** LightGBM و LSTM با tuning واقعی، نه فقط یک MLP.
- **بازنگاشت خروجی:** تصمیم بگیریم decoder (نکته‌ی ۵) خروجی را کران‌دار کند یا نه، و همان را برای مدل کنترل هم اعمال کنیم.

- معماری مدار: مقاله از RealAmplitudes (با Qiskit) و ZFeatureMap استفاده کرده؛ طرح ما StronglyEntanglingLayers (با PennyLane) و AngleEmbedding ذکر Methods است. تفاوت را در می‌کنیم.

نقطه‌ی احتیاط: این مقاله «شاهد» نیست، «الگو» است. ادعای «کوانتوم بهتر است» در مقاله‌ی ما نباید به آن تکیه کند.

---

۵. سؤال‌های محتمل استاد

1. چرا از مقاله‌ای که موضوعش پخش بار است الگو گرفتی؟ (پاسخ: ساختار هیبریدی و طراحی ۵ معیاره، نه موضوع.)
2. چطور ۶۰ گام زمانی را به ۴ تا ۸ کیوبیت می‌دهی؟
3. اگر مدل کوانتومی بازنده شد، پیام مقاله چیست؟
4. چرا مدل کنترل هم‌اندازه لازم است و آیا کافی است؟ (Bowles پارامتر برابر را کافی نمی‌داند.)
5. زمان اجرای شبیه‌ساز برای ۳۳۰ هزار گام شدنی است؟

---

۶. با چشم خودت ببین (حدود ۱۰ دقیقه)

1. Fig. 5: ساختار QCNN. ببین PQC (نکته‌ی ۶) جای یک لایه نشسته یا اضافه شده.
2. Section 5.1.3 و Fig. 7: آزمایش حجم داده (نمونه‌ی ما برای RQ2).
3. Section 5.2.1 و 5.2.2: چقدر برای NN tuning شده و برای QCNN چه خبر است.
4. Fig. 12: جاروب تعداد کیوبیت.
5. Section 6، «پاراگراف آخر: اذعان نویسندگان به «ارزش افزوده نیاز به بررسی بیشتر دارد».

---

۷. English block for `docs/literature.md`

5. Kaseb et al. — Quantum neural networks for power flow analysis (EPSR 2024)

Idea. First systematic study of quantum and hybrid quantum-classical neural networks as surrogates for AC power flow (inputs p, q per bus; outputs voltage magnitude and angle, labels from Newton-Raphson). Compares a classical NN, a pure QNN and a hybrid QCNN on five criteria: generalization, robustness to noisy training data, training-set size needed, training error, and training stability.

Method. Qiskit Aer simulator only. QNN: ZFeatureMap (H + Rz with arctan scaling) → RealAmplitudes ansatz (Ry-CNOT-Ry, 4n parameters) → Z measurements → linear rescaling to physical ranges. QCNN: linear encoder → PQC → linear decoder. 4-bus main case, 33-bus supplementary. 512 synthetic samples (25/25/50 split, so 128 training points), 1000 epochs, Adam, MSE, 6 qubits (chosen from a 1–7 sweep), 1024 shots (chosen by convergence), hardware-noise sweep 0–10% on the QNN. The classical NN (7 hidden layers) was tuned by sensitivity analysis over depth, learning rate, weight decay and dropout.

Results. With 128 noisy training points, test MSE is 41% (QNN) and 52% (QCNN) lower than the NN; training MSE is 48% and 54% lower. The NN needs about 4x more data to approach

the QCNN and is still worse. The NN degrades by up to 2x as training noise grows. On the 33-bus system under extreme voltage conditions the QCNN reaches a maximum test MSE of 0.011 p.u. versus 0.032 p.u. for the NN.

Weaknesses. Synthetic i.i.d. data, tiny systems, simulator only (authors say NISQ hardware is impractical today and that added value needs further study). Tuning effort is documented for the NN but not for the quantum models; parameter counts and a same-architecture classical control are not reported; no multiple seeds or significance tests are mentioned; the quantum output is bounded by a physical-range rescaling that may act as a prior the NN lacks; no entanglement ablation; the "stability" metric is within-run loss variation, not variance across seeds.

Use in our project. Template for the hybrid QCNN (linear encoder–PQC–linear decoder), the qubit-count sweep, the shot-convergence check, the noise sweep and the data-fraction experiment. We add what it lacks: a same-architecture classical control, an entanglement ablation, an equal tuning budget, three seeds, and Diebold–Mariano tests. It is a design template, not evidence of advantage.