خلاصه‌ی مقاله ۸: Meyer و همکاران، «Rethinking Evaluation in the Era of Time Series Foundation Models: (Un)known Information Leakage Challenges»

مشخصات: Marcel Meyer, Sascha Kaltenpoth, Kevin Zalipski, Oliver Müller (دانشگاه Paderborn). arXiv:2510.13654، نسخه‌ی v3 (۲۵ فوریه ۲۰۲۶). مجوز CC BY 4.0. نوع مقاله: **position paper**، یعنی استدلال و شواهد موردی، نه یک مطالعه‌ی تجربی بزرگ.

منبع این خلاصه: متن کامل نسخه‌ی HTML (شامل پیوست‌ها). جدول lineage مقاله (فایل CSV در GitHub) را **نتوانستم بخوانم**، چون GitHub دسترسی خودکار را می‌بندد. بخش‌هایی که به آن وابسته‌اند با ⚠ مشخص شده‌اند.

> **نکته‌ی مهم:** این مقاله اصلاً به MIT Supercloud یا توان دیتاسنتر اشاره نمی‌کند. استدلال «Supercloud در داده‌ی پیش‌آموزش نیست» در این مقاله وجود ندارد و باید از طرف خودمان ساخته و **راستی‌آزمایی** شود.

---

۱. خلاصه در یک پاراگراف

مدل‌های پایه‌ی سری زمانی (TSFM) روی مجموعه‌های عظیم و ناهمگن آموزش می‌بینند و zero-shot پیش‌بینی می‌کنند. همین موضوع ارزیابی را مشکل می‌کند، مثل «بحران ارزیابی» در LLMها. نویسندگان دو نوع نشت اطلاعات را تشخیص می‌دهند: **(۱) نشت مستقیم:** داده‌ای که در پیش‌آموزش یا fine-tuning مدلی بوده، در آزمون مدل دیگری (یا همان مدل) دوباره ظاهر می‌شود. **(۲) نشت غیرمستقیم:** سری‌های هم‌بسته‌ی هم‌زمان (مثلاً شاخص‌های بورس در دوره‌ی کرونا) که اشتراک علّی دارند، اطلاعات دوره‌ی آزمون را بدون دیدن هیچ نقطه‌ی آزمونی به مدل می‌رسانند. پیشنهادشان دو الزام برای benchmarkهای آینده است: داده‌ی آزمون واقعاً تازه باشد، و دوره‌ی آزمون **بعد از آخرین زمان پیش‌آموزش هر مدل مقایسه‌شده** باشد.

---

۲. مفاهیم کلیدی

شواهد نشت مستقیم

- تحلیل lineage روی **۲۲ TSFM** و **۴۰۱ دیتاست:** هر تیم ترکیب متفاوتی از دیتاست‌ها را برای پیش‌آموزش، train/test و zero-shot استفاده کرده و فقط **۶٪** دیتاست‌ها هرگز در پیش‌آموزش یا fine-tuning هیچ مدلی نبوده‌اند.
- مثال: Australian Electricity Demand هم برای پیش‌آموزش (Timer، Lag-Llama)، هم train/test (Moirai) و هم zero-shot (TimesFM، Chronos) استفاده شده است.
- دیتاست‌ها **تغییر نام و بازبسته‌بندی** می‌شوند: «Elecdemand» زیرمجموعه‌ی ۱/۱۰۰۰ همان Australian Electricity Demand است؛ ElectricityLoadDiagrams20112014 با نام‌های «Electricity» و «ECL» ظاهر می‌شود. پس باید خود داده را مقایسه کرد، نه نام را.
- مورد Solar: نسخه‌های مختلف (همه‌ی ایالت‌های آمریکا، فقط آلاباما، با فرکانس‌های مختلف) از یک منبع در چند مخزن پخش شده‌اند.
- موارد مستند: در یک benchmark (FoundTS) سه دیتاست آزمون که قبلاً در پیش‌آموزش TimesFM، UniTS و TTM بوده‌اند باعث شد MSE بین **۴۷٪ تا ۱۸۴٪** بهتر از بهترین مدل‌های بدون نشت شود، در حالی که مزیت بهترین TSFM روی دیتاست‌های بدون نشت فقط ۰٫۳٪ تا ۱۴٪ بود. دو مقاله‌ی حوزه‌ی انرژی (Electricity در Saravanan و Spain در Montet) روی دیتاست‌هایی آزمون گرفته‌اند که در پیش‌آموزش مدل‌های آزمون‌شده بوده است.

- آزمایش Moirai (از Aksu و همکاران، GIFT-Eval): فقط ۰٫۱٪ نشت عمدی، میانگین MAPE را در افق‌های کوتاه، میانی و بلند به ترتیب حدود ۸، ۱۵ و ۲۹ واحد درصد کاهش داد. اثر برای مدل بزرگ (L) قوی‌تر بود (حدود ۳۴ واحد در برابر ۴ برای S). یعنی ظرفیت مدل اثر نشت را تقویت می‌کند.

شواهد نشت غیرمستقیم

- **مادرید (Rodrigo و Ortiz):** سری‌های هم‌بسته‌ی حمل‌ونقل، هدف zero-shot مترو. وقتی سری‌های دیگر تا انتهای دوره‌ی آزمون در آموزش بودند، MAE برابر ۲۴۸٫۲۴ شد در برابر ۴۳۹٫۱۴ (حدود ۴۳٪ بهتر).
- **آزمایش کرونا (خود مقاله):** یک Time-Series Transformer از صفر، دو مجموعه‌ی آموزشی تقریباً یکسان (۴۸۴ سری)، با ۷ شاخص بورس تا دسامبر ۲۰۱۹ (بدون نشت) یا تا دسامبر ۲۰۲۰ (با هم‌پوشانی زمانی)، هدف: S&P 500 که هرگز دیده نشده. سهم داده‌ی نشتی حدود ۱۶۰۰ از بیش از ۲۰۵ هزار مشاهده.
  - تا ۱ مه ۲۰۲۰ (دوره‌ی سقوط): میانگین MAE حدود ۱۹۰ (با نشت) در برابر حدود ۲۱۷ (بدون نشت)؛ در ۸ از ۱۰ seed بهتر، تا حدود ۳۷٪.
  - بعد از آن: ۱۰۸٫۷ در برابر ۱۰۸٫۳، یعنی مزیت **مخصوص دوره‌ی اشتراک علّی** بود، نه یک مزیت عمومی.
- **بحث فرکانس:** نسخه‌های یک فرایند با فرکانس‌های مختلف باید **وابسته** در نظر گرفته شوند.

دو الزام پیشنهادی

1. **انعطاف کامل در داده‌ی پیش‌آموزش:** نباید توسعه‌دهنده را محدود کرد؛ مسئولیت جدا نگه‌داشتن بر دوش طراح benchmark است و داده‌ی آزمون باید واقعاً تازه باشد.
2. **دوره‌ی آزمون بعد از آخرین زمان پیش‌آموزش (`t_now + 1`):** اگر دیرترین زمان پیش‌آموزش میان همه‌ی مدل‌های مقایسه‌شده t باشد، تمام مشاهده‌های آزمون باید از t+1 به بعد باشد.

مسئله‌ی انتخاب دیتاست (Roque و همکاران، ذکرشده در مقاله): با ۴ دیتاست آزمون دستچین‌شده، ۴۶٪ مدل‌ها می‌توانند state-of-the-art به نظر برسند.

---

۳. ضعف‌ها

1. **position paper است:** هیچ TSFM واقعی را برای نشت زمانی آزمایش نکرده؛ آزمایش اصلی با یک مدل کوچک از صفر انجام شده و نویسندگان خودشان می‌گویند اندازه‌ی اثر در TSFMهای واقعی «عمدتاً ناشناخته» است.
2. **آزمون seed:** مجموعه‌ی کوچک (۴۸۴ سری). ۱۰ seed (S&P 500) **آزمایش کرونا:** یک رویداد، یک سری هدف هست ولی نتیجه برعکس بود. بعد از **معناداری گزارش نشده:** میانگین‌ها ۱۹۰٫۱۵ و ۲۱۶٫۸۸ با انحراف معیار حدود ۱۷ و ۲۲ و در دو دوره‌ی سقوط هم مدل با نشت کمی بدتر بود (۱٫۴٪).
3. **از خود آن‌ها نیست Moirai آزمایش** (مثلاً در Aksu از) و در جدول مقاله همه‌ی سلول‌ها به نفع نشت نیستند (افق میانی sz_taxi).
4. **روی خواندن مقاله‌ها و کدها استوار است،** نه تأیید مستقل؛ خودشان می‌گویند تأیید یکسان‌بودن داده در مخازن **lineage تحلیل** (مثلاً در TimesFM traffic hourly) «مختلف دشوار است. موارد «هم‌پوشانی احتمالی با لحن احتیاط آمده‌اند.
5. **الزام ۲ در عمل بسیار سخت‌گیرانه است:** تقریباً هر داده‌ی تاریخی برای مدل‌های جدید باطل می‌شود و راه‌حل عملی فقط داده‌ی تازه، مشخصی ارائه نمی‌شود benchmark. داده‌ی مصنوعی یا مسابقه‌ی زنده است.
6. **روش تشخیص نشت ارائه نمی‌شود** (مثلاً membership inference)، فقط ردیابی منبع.
7. **ادعای «فرکانس‌های مختلف وابسته‌اند» استدلال شده، آزمایش نشده است.**

8. نتیجه شده است (Moirai S/B/L) **مدل‌های بزرگ‌تر مستعدتر»** فقط از یک خانواده.
9. را بررسی نمی‌کند؛ برای آن‌ها (ما LSTM و LightGBM مثل) **مدل‌های محلی و مدل‌های آموزش‌دیده روی داده‌ی خودمان** تقسیم زمانی ساده کافی است.

---

۴. پیام برای پروژه‌ی ما

آنچه می‌دانیم و آنچه نمی‌دانیم

- مقاله **نمی‌گوید** Supercloud در پیش‌آموزش نیست. بار اثبات با ماست.
- ⚠ **کار بررسی ۱ (لازم):** CSV مقاله را (فایل ~۳۷ گیلوبایت، بدون مشکل VPN) دانلود کن و ستون «Dataset» و «Source» را برای کلیدواژه‌هایی مثل `supercloud`، `gpu`، `hpc`، `datacenter`، `cluster`، `power` جست‌وجو کن. نتیجه (حتی «چیزی پیدا نشد») را در بخش Data مقاله بنویس. نبودِ نام در جدول، اثبات نبود داده نیست.
- ⚠ **کار بررسی ۲:** کارت مدل و مقاله‌ی هر مدلی که zero-shot اجرا می‌کنیم (TimesFM، Chronos، و Toto که روی متریک‌های پایش زیرساخت آموزش دیده) را برای فهرست داده‌ی پیش‌آموزش بخوان. برای Toto مخصوصاً بررسی کن که داده‌ی پایش (Datadog) چه نوع سری‌هایی دارد و آیا بخش عمومی‌اش HPC/GPU را شامل می‌شود. پیش‌آموزش‌های بسته را نمی‌توان کامل بررسی کرد؛ همین را صادقانه می‌نویسیم.

نشت غیرمستقیم برای ما

- دوره‌ی آزمون ما (۱۵٪ آخر از فوریه تا اکتبر ۲۰۲۱، یعنی تقریباً پاییز ۲۰۲۱) **قطعاً قبل از** زمان قطع پیش‌آموزش همه‌ی مدل‌هاست؛ پس الزام ۲ مقاله را **نمی‌توانیم** برآورده کنیم. باید بپذیریم که zero-shot روی این داده نمی‌تواند «عاری از نشت غیرمستقیم» اعلام شود.
- اشتراک علّی ممکن بین توان یک خوشه‌ی دانشگاهی و سری‌های دیگر در همان دوره: چرخه‌ی هفتگی و روزانه، تقویم دانشگاهی، دوره‌ی کرونا. ریسک را «محتمل ولی کم‌اثر» می‌دانیم؛ اما فقط به‌عنوان **محدودیت** ثبت می‌کنیم، نه ادعای حل‌شده.

تصمیم‌های پروتکلی پیشنهادی (به نشست ۱ ببر)

1. مقایسه‌ی اصلی RQ1 و RQ2 بر پایه‌ی مدل‌هایی است که **روی train split خودمان** آموزش دیده‌اند. نتایج Chronos/TimesFM/Toto zero-shot را **ثانویه** و با تذکر نشت گزارش کن.
2. جدول کوچک «منبع داده‌ی پیش‌آموزش هر مدل zero-shot» در پیوست مقاله بگذار (نتیجه‌ی کارهای بررسی ۱ و ۲).
3. zero-shot را روی **PM100 (۲۰۲۰)** هم اجرا کن و رتبه‌ی مدل‌ها را مقایسه کن. این ایده‌ی خودمان است، نه از مقاله: اگر رتبه‌ها روی دو دیتاست ناسازگار باشد، شک به حافظه‌سازی یا ناپایداری جدی‌تر می‌شود. (دلیل قطعی نیست.)
4. ادعاها را به «این دامنه و این دیتاست» محدود کن، چون با دو دیتاست بحث انتخاب‌گزینشی (Roque) به تعمیم‌دادن ادعا مربوط می‌شود.
5. این مقاله را در Related Work/Limitations ارجاع بده؛ جمله‌ی پیشنهادی: «To our knowledge … we could not verify … see Meyer et al.».

آنچه نگران آن نیستیم: برای مدل‌هایی که خودمان آموزش می‌دهیم (آماری، N-HiTS، PatchTST، LSTM، LightGBM، QRC، QCNN) تقسیم زمانی ۷۰/۱۵/۱۵ بدون shuffle و نرمال‌سازی فقط روی train همان رویه‌ی کلاسیک است که مقاله هم تأیید می‌کند.

---

۵. سؤال‌های محتمل استاد

1. «از کجا می‌دانی Chronos/TimesFM قبلاً این داده را ندیده‌اند؟» (پاسخ صادقانه: نمی‌توانیم قطعی بگوییم؛ بررسی lineage انجام شد، نتیجه‌اش این است، و zero-shot ثانویه است.)
2. چرا zero-shot را اصلاً نگه می‌داری؟ (چون ترند روز است و مقایسه با مدل آموزش‌دیده روی داده‌ی خودمان معنادار است، با هشدار.)
3. آیا نشت زمانی برای ما مهم است، وقتی تقسیم ما زمانی است؟ (برای مدل‌های محلی نه؛ برای مدل‌های پایه بله.)
4. چرا PM100؟ (آزمون تعمیم و بررسی پایداری رتبه‌ها.)

---

۶. با چشم خودت ببین (حدود ۱۰ دقیقه)

1. Fig. 2 (نمودار Sankey): ببین چقدر دیتاست‌ها بین مدل‌ها مشترک‌اند.
2. §3.2 و Fig. 4 به‌همراه Table 4 و دو seed در پیوست: به انحراف معیارها دقت کن. برعکس
3. §4: دو الزام و ببین کدام را ما نمی‌توانیم برآورده کنیم.
4. Appendix A.1: ۴۷–۱۸۴٪ اعداد موردی.
5. Table 1: ببین فهرست ۲۲ مدل؛ Chronos (و Chronos-2 در CSV) و TiRex و Toto کجا هستند.

---

۷. English block for `docs/literature.md`

8. Meyer et al. — Rethinking Evaluation in the Era of Time Series Foundation Models: (Un)known Information Leakage Challenges (arXiv 2510.13654, v3, Feb 2026)

Idea. Position paper arguing that zero-shot evaluation of time series foundation models (TSFMs) is vulnerable to two kinds of information leakage: (1) direct train–test sample overlap caused by reusing public datasets for both pre-training and testing, and (2) indirect leakage from temporally overlapping but nominally disjoint series that share a common driver.

Method. Dataset-lineage analysis of 22 TSFMs and 401 datasets; case studies of documented overlaps (e.g., Electricity and Spain in energy-load benchmarks); a re-analysis of a deliberate Moirai leakage experiment (0.1% leaked data); and a controlled experiment training a small Time-Series Transformer from scratch with or without seven stock indices covering the 2020 COVID crash, tested zero-shot on the S&P 500. Proposes two requirements: test data must be provably novel, and the test period must start after the latest pre-training timestamp of every compared model.

Results. Only 6% of the 401 datasets never appear in any model's pre-training or fine-tuning corpus. Documented leakage cases show large apparent gains (e.g., 47–184% lower MSE on leaked datasets versus 0.3–14% advantage on clean ones). In the COVID experiment the leaky model had a lower MAE during the crash period (about 190 vs 217, better in 8 of 10 seeds) and no advantage afterwards (about 108.7 vs 108.3). The Madrid transport example shows about 43% lower MAE from temporally overlapping correlated series.

Weaknesses. Position paper; no production TSFM is tested for temporal leakage, and the authors acknowledge the real effect size is unknown. The COVID experiment uses one event and one target series, reports no significance test, and two seeds go the other way. The Moirai experiment is borrowed from prior work. Lineage relies on reading papers and code, so provenance cannot be verified independently. Requirement 2 is hard to satisfy for historical benchmarks and no concrete benchmark is provided. No leakage-detection method is offered. It does not mention data-center power data.

Use in our project. Zero-shot Chronos, TimesFM and Toto results are reported as secondary, with an explicit leakage caveat and a table of known pre-training sources (to be verified from the lineage CSV and model cards). Our test period (autumn 2021) precedes every model's pre-training cutoff, so Requirement 2 cannot be met; this is stated as a limitation. Models we train ourselves use a strict chronological split with train-only normalization, which this paper does not call into question. PM100 is used as a second dataset to check rank stability.