خلاصه‌ی مقاله ۱۰: Gibbs و Candès، «Adaptive Conformal Inference Under Distribution Shift»

مشخصات: Isaac Gibbs, Emmanuel J. Candès (Stanford). arXiv:2106.00170، نسخه‌ی v3 (۲۸ اکتبر ۲۰۲۱). طبق دستورالعمل پروژه در NeurIPS 2021 چاپ شده؛ صفحه‌ی arXiv این را ذکر نکرده است ⚠️. کد R نویسندگان: `github.com/isgibbs/AdaptiveConformal`.

منبع این خلاصه: متن کامل مقاله و پیوست (شامل اثبات‌ها). نسخه‌ی بهبودیافته‌ی همین ایده (JMLR 2024، با انتخاب خودکار گام) را که در دستورالعمل پروژه آمده **نخواندم** ⚠️.

---

۱. خلاصه در یک پاراگراف

کلاسیک از هر مدل پیش‌بینی، بازه‌ی اطمینانی با پوشش تضمین‌شده می‌سازد، به شرط **تبادل‌پذیری** داده‌ها (exchangeability). یک پوشش ACI .در سری زمانی با تغییر توزیع، این شرط برقرار نیست و پوشش واقعی از هدف فاصله می‌گیرد Conformal prediction دور مدل پیش‌بینی (یا مدل کوانتایل) است که فقط **یک پارامتر** را به‌صورت برخط نگه می‌دارد: سطح خطای مؤثر `α_t`. بعد از هر گام، اگر پیش‌بینی بازه را از دست داد `α_t` کاهش می‌یابد (بازه گشادتر می‌شود) و اگر پوشاند، کمی افزایش می‌یابد. نتیجه‌ی نظری: **فراوانی بلندمدت** و پیش‌بینی شمارش رأی (GARCH با) **می‌رسد، بدون هیچ فرضی درباره‌ی توزیع داده.** آزمایش‌ها: پیش‌بینی نوسان بازار سهام **α خطا به** CQR) با) در شب انتخابات آمریکا ۲۰۲۰.

---

۲. مفاهیم کلیدی

Split conformal و چرا تبادل‌پذیری لازم است

- مدل روی بخشی از داده آموزش می‌بیند؛ روی یک مجموعه‌ی calibration جدا، امتیازهای انطباق `S(X,Y)` (مثلاً خطای مطلق `|μ̂(X) − y|`) محاسبه می‌شود. بازه = همه‌ی yهایی که امتیازشان از چندک `(1−α)` امتیازهای calibration کمتر باشد.
- اگر calibration و نقطه‌ی آزمون تبادل‌پذیر باشند، رتبه‌ی امتیاز آزمون میان امتیازها یکنواخت است و پوشش دقیقاً `⌈n(1−α)⌉/(n+1)` می‌شود. وقتی توزیع در زمان تغییر کند، رتبه دیگر یکنواخت نیست و این تضمین از بین می‌رود.

قاعده‌ی به‌روزرسانی ACI (معادله‌ی ۲) `α_{t+1} = α_t + γ (α − err_t)`، با `err_t = 1` اگر `Y_t` در بازه‌ی `Ĉ_t(α_t)` نبود و ۰ اگر بود. شروع با `α_1 = α`.

- با α = ۰٫۱: هر خطا `α_t` را `γ(1−α) = 0.9γ` کم می‌کند و هر پوشش درست آن را `0.1γ` زیاد می‌کند. یعنی یک خطا به اندازه‌ی ۹ پوشش درست اثر دارد، و در حالت تعادل ۱۰٪ مواقع خطا رخ می‌دهد.
- ایده‌ی پشت آن: یک مقدار بهینه‌ی متغیر با زمان `α_t*` وجود دارد که اگر در `Q̂_t(1−۰)` گذاشته شود، خطای واقعی دقیقاً α شود؛ الگوریتم این هدف متحرک را دنبال می‌کند. معادل گرادیان نزولی برخط روی pinball loss است (ضمیمه‌ی A.1)، ولی نویسندگان می‌گویند تحلیل regret این «ردیابی» را نمی‌گیرد و تحلیل جدا می‌سازند.
- گونه‌ی وزن‌دار (معادله‌ی ۳) با وزن‌های `0.95^{t−s}`: نتایج تقریباً یکسان، مسیر `α_t` هموارتر.

تضمین اصلی (Proposition 4.1)، بدون فرض روی داده: `| (1/T) Σ err_t − α | ≤ (max{α_1, 1−α_1} + γ) / (T·γ)` برای هر T، تقریباً مطمئن. به‌علاوه `α_t ∈ [−γ, 1+γ]` همیشه (Lemma 4.1).

- مثال عددی با آرایه‌های پروژه (محاسبه‌ی خودم از همین فرمول): با $\gamma = ۰٫۰۰۵$، $\alpha = ۰٫۱$ و حدود ۵۰ هزار گام آزمون (۱۵٪ از حدود ۳۳۰٫۵ هزار گام)، حد بالای خطای پوشش حدود `0.905/(0.005·50000) ≈ 0.0036`، یعنی کمتر از ۰٫۴ واحد درصد. این یک **آزمون واحد (assert) ارزان برای پیاده‌سازی ما** هم هست.

گام γ (بخش ۲.۱ و Theorem 4.2): تعادل بین سازگاری و پایداری. γ بزرگ‌تر ← سازگارتر ولی `α_t` پرنوسان‌تر. γ خیلی کوچک ← رفتار شبیه روش غیرتطبیقی. نظریه (فقط در مدل HMM با $\hat{Q}$ ثابت): بهینه‌ی γ متناسب با جذر اندازه‌ی تغییر `|α*_{t+1} − α*_t|`. در آزمایش‌ها $\gamma = ۰٫۰۰۵$.

آزمایش‌ها

- **نوسان بازار:** پیش‌بینی نقطه‌ای با GARCH(1,1) که هر گام با ۱۲۵۰ روز آخر دوباره برازش می‌شود؛ امتیاز نرمال‌شده `|V_t − σ̂²_t| / σ̂²_t`؛ $\alpha = ۰٫۱$. معیار: **local coverage** (میانگین پوشش در یک پنجره‌ی ۵۰۰ روزه حول t). روش «غیرتطبیقی» همان کار را با `α_t = α` ثابت می‌کند **ولی چندک را هر گام از ۱۲۵۰ امتیاز اخیر دوباره می‌سازد**، پس baseline آن‌ها ساکن نیست، «بازکالیبره‌شونده‌ی ثابت‌α» است. در ۴ سهام از ۱۲ سهام (انتخاب‌شده چون شکست روش غیرتطبیقی واضح بود) روش غیرتطبیقی از هدف ۹۰٪ فاصله گرفت (مثلاً Fannie Mae در بحران ۲۰۰۸) و ACI در محدوده‌ی تغییرات یک دنباله‌ی Bernoulli مستقل ماند. نتایج سایر سهام در ضمیمه (Fig. 9).
- **شب انتخابات ۲۰۲۰:** CQR با رگرسیون کوانتایل خطی، حدود ۳۱۱۱ شهرستان؛ ترتیب با منطقه‌ی زمانی (شرق اول، هاوایی آخر) تا رانش بسازد؛ هر گام مدل دوباره برازش می‌شود. روش غیرتطبیقی در تغییر منطقه‌ی زمانی افت پوشش دارد؛ ACI نزدیک ۹۰٪ می‌ماند.

اهمیت امتیاز انطباق (بخش ۵): عملکرد ACI به **ایستایی تقریبی امتیاز** وابسته است. با امتیاز بدون نرمال‌سازی `|V_t − σ̂²_t|` پوشش نوسان بسیار بیشتری از هدف می‌گیرد؛ نرمال‌سازی با `σ̂²_t` حیاتی است. بزرگ‌تر کردن γ تا حدی جبران می‌کند. همچنین برای بازه‌ی کوتاه‌تر باید مدل را هر گام با جدیدترین داده برازش کرد.

محدودیت‌هایی که خود مقاله می‌گوید (بخش ۷): روش فرض می‌کند `Y_t` در هر گام آشکار می‌شود (نه تأخیری یا دسته‌ای)؛ تئوری ۴٫۲ فقط برای یک مدل HMM و $\hat{Q}$ ثابت؛ انتخاب γ هنوز ابتکاری است؛ آزمایش‌ها فقط دو حوزه.

---

۳. ضعف‌ها

1. **ضمانت فقط بلندمدت و میانگین است**، نه محلی یا شرطی. روی هر زیرمجموعه‌ی خاص (مثلاً فقط لحظه‌های جهش) هیچ تضمینی نیست.
2. **عرض بازه کنترل نمی‌شود.** وقتی `α_t < 0` شود `Q̂_t(1−α_t) = ∞` و بازه بی‌نهایت می‌شود (این در اثبات Lemma 4.1 هم هست)؛ وقتی `α_t > 1` شود مجموعه‌ی پیش‌بینی تهی می‌شود. پس پوشش بلندمدت را می‌توان با بازه‌های خیلی بزرگ یا تهی در برخی گام‌ها هم به دست آورد. مقاله هیچ **جدول یا نموداری از عرض بازه** نشان نمی‌دهد (فقط پوشش) ⚠.
3. **تئوری در حالت تطبیقی محدود است:** HMM، $\hat{Q}$ ثابت و فرض‌هایی که نویسندگان می‌گویند «دقیقاً در عمل برقرار نیست». حدود Theorem 4.1 و 4.2 به اندازه‌ی تغییر α^* وابسته‌اند که مقدارش مجهول است.
4. **باید `Y_t` فوراً در دسترس باشد.** این برای ما مشکل‌ساز است (بخش ۴).
5. **آزمایش‌ها محدود و تا حدی گزینشی:** ۲ حوزه، یک $\alpha = ۰٫۱$، یک $\gamma = ۰٫۰۰۵$؛ ۴ سهام از ۱۲ تا نمایش شکست روش مرجع انتخاب شده‌اند؛ مقایسه با روش‌های تطبیقی دیگر ندارد؛ معیار تطبیق با Bernoulli بصری است، نه آزمون آماری.
6. **وابستگی به ایستایی امتیاز:** اگر امتیاز خوب نرمال نشود، `α*_t` زیاد می‌پرد و عملکرد افت می‌کند.

7. **داده‌ی ما خودهمبسته است** (مقادیر یک‌دقیقه‌ای همسایه). Proposition 4.1 به همبستگی کاری ندارد و معتبر می‌ماند؛ اما Theorem 4.1 فرض ساختار Markov دارد و نباید برای تفسیر آماری پوشش‌های محلی به آن تکیه کرد.

---

۴. پیام برای پروژه‌ی ما (RQ3)

چرا split conformal ساده برای ما کافی نیست: calibration روی مجموعه‌ی اعتبارسنجی (۱۵٪ میانی) و آزمون روی ۱۵٪ آخر است؛ این دو ماه‌های متفاوت‌اند و بار GPU بین آن‌ها تغییر می‌کند. یعنی تبادل‌پذیری عملاً نقض است.

تصمیم‌های پروتکلی پیشنهادی (به نشست ۱ ببر)

1. **سه روش را گزارش کن** (دستور پروژه فقط split و ACI را می‌گفت؛ خوانش این مقاله نشان می‌دهد baseline میانی لازم است):
   - (الف) split conformal ایستا: calibration یک بار روی اعتبارسنجی؛
   - (ب) split conformal با **calibration لغزان** (چندک از N امتیاز اخیر)، α ثابت. این همان baseline «غیرتطبیقی» خود مقاله است؛
   - (ج) ACI روی (ب).
2. **امتیاز انطباق را قبل از دیدن آزمون ثابت کن.** برای توان GPU که ناهمواریانس است، امتیاز نرمال‌شده (مثلاً خطای مطلق تقسیم بر برآورد مقیاس مثل MAD لغزان باقیمانده‌ها) یا CQR. بر اساس بخش ۵ همین انتخاب ممکن است از γ مهم‌تر باشد. (برای مدل‌هایی که فقط پیش‌بینی نقطه‌ای می‌دهند مثل LSTM و LightGBM، مقیاس را باید جدا برآورد کنیم؛ این تصمیم طراحی ماست، نه از مقاله.)
3. **γ و α:** $\alpha = ۰,۱$ مطابق پروتکل (هدف ۹۰٪)؛ $\gamma = ۰,۰۰۵$ به‌عنوان نقطه‌ی شروع مقاله، به‌علاوه‌ی تحلیل حساسیت (مثلاً $۰,۰۰۱$، $۰,۰۰۵$، $۰,۰۱$)؛ بازه‌ی γ را قبل از دیدن نتایج آزمون ثابت کن (یا روی اعتبارسنجی انتخاب کن).
4. **افق‌های ۵ و ۱۵ دقیقه ← بازخورد تأخیری.** در افق h گامی، `Y_{t+h}` فقط h گام بعد معلوم می‌شود، پس `err_t` همان لحظه در دسترس نیست. مقاله این حالت را صریحاً «مسئله‌ی باز» می‌نامد. راه‌حل ابتدایی: برای هر افق یک ACI جدا اجرا کن و α را فقط با خطاهای تا زمان `t-h` به‌روز کن (به‌روزرسانی تأخیری). **تضمین Proposition 4.1 برای این حالت اثبات‌شده نیست؛** احتمالاً با تأخیر کمی بدتر می‌شود (برآورد خودم، تأییدنشده ⚠). حتماً پوشش واقعی را روی آزمون گزارش کن و از ادعای «تضمین‌شده» خودداری کن. اگر فرصت شد، نسخه‌ی بهبودیافته‌ی ۲۰۲۴ (JMLR) را برای حالت تأخیری بررسی کن.
5. **پیاده‌سازی:** قاعده‌ی به‌روزرسانی یک خط است؛ مستقیم پیاده کن و `assert` روی حد Proposition 4.1 بگذار (البته برای افق ۱ دقیقه، بدون تأخیر). MAPIE ممکن است ACI را هم داشته باشد؛ راستی‌آزمایی نشده ⚠. برای جلوگیری از بازه‌ی بی‌نهایت/تهی، `α_t` را برای ساخت بازه به یک محدوده‌ی عملی برش بزن (و این را در Methods ثبت کن).

چه چیزی گزارش کنیم (طبق دستورالعمل + نکته‌های مقاله):

- پوشش کلی و **پوشش محلی** (میانگین لغزان با پنجره‌ی ثابت، مثلاً یک روز = ۱۴۴۰ گام).
- **عرض بازه** (میانگین و میانه)؛ مقاله این را نشان نمی‌دهد و در ارزیابی ما باید باشد تا «پوشش با بازه‌ی بی‌معنا» دیده شود.
- **مسیر** `α_t` در زمان (مثل ضمیمه‌ی A.3).
- پوشش **جدا برای گام‌های عادی و گام‌های جهش** (جهش = `|ΔP|` بالاتر از صدک ۹۵ داده‌ی آموزش، طبق پروتکل).

انتظار صادقانه برای RQ3: ACI فقط پوشش میانگین بلندمدت را تضمین می‌کند. چون جهش‌ها از تعریف فقط حدود ۵٪ گام‌ها هستند و ناگهانی‌اند، **پوشش در گام‌های جهش احتمالاً زیر ۹۰٪** می‌ماند حتی با ACI. این فرضیه‌ی ماست (نه ادعای مقاله)؛ اگر درست درآمد، یک یافته‌ی خوب و صادقانه است. اگر بخواهیم پوشش شرطی بهتر شود، باید طبقه‌بندی (مثلاً calibration جدا برای رژیم‌های «نوسان اخیر

بالا/پایین») را امتحان کنیم؛ توجه: رژیم باید از اطلاعات قبل از t ساخته شود، نه از خودِ جهش (چون جهش را در زمان پیش‌بینی نمی‌دانیم). این ایده‌ی خودمان است و در این مقاله نیست.

---

۵. سؤال‌های محتمل استاد

1. «چرا split conformal ساده کافی نیست؟» (تبادل‌پذیری و تغییر ماه به ماه.)
2. «ACI چه چیزی را تضمین می‌کند و چه چیزی را نه؟» (بلندمدت و میانگین؛ نه محلی و نه شرطی؛ نه عرض.)
3. «برای افق ۱۵ دقیقه چطور بازخورد را می‌گیری؟» (به‌روزرسانی تأخیری؛ تضمین ثابت‌نشده.)
4. «γ را چطور انتخاب می‌کنی؟» (روی اعتبارسنجی یا تحلیل حساسیت؛ مقاله هم فقط راهنمای ابتکاری دارد.)
5. «اگر پوشش در جهش‌ها پایین ماند چه؟» (گزارش می‌کنیم؛ جهش‌ها نادرند و ACI برای میانگین است.)

---

۶. با چشم خودت ببین (حدود ۱۰ دقیقه)

1. معادله‌ی (۲) و Proposition 4.1: ببین چرا اثبات یک تلسکوپ ساده است (Lemma 4.1).
2. Fig. 1: پوشش محلی، روش غیرتطبیقی در برابر ACI (و کادر «Fannie Mae»).
3. Fig. 2 و بخش ۵: اثر امتیاز نرمال‌نشده.
4. Fig. 3 (شب انتخابات): افت پوشش در تغییر منطقه‌ی زمانی.
5. بخش ۷ (Discussion): فهرست مسائل باز، به‌ویژه بازخورد تأخیری.
6. ضمیمه‌ی A.3: مسیرهای `α_t` (چیزی که ما هم باید رسم کنیم).

---

۷. English block for `docs/literature.md`

10. Gibbs & Candès — Adaptive Conformal Inference Under Distribution Shift (arXiv 2106.00170, NeurIPS 2021)

Idea. Split conformal prediction guarantees coverage only under exchangeability, which fails for time series with distribution shift. Adaptive conformal inference (ACI) wraps any point predictor or quantile model and tracks a single online parameter, the effective miscoverage level α_t, so that long-run coverage frequency matches the target without assumptions on the data-generating process.

Method. After each step, set `α_{t+1} = α_t + γ(α − err_t)`, where `err_t` indicates whether `Y_t` fell outside the prediction set built at level α_t (equivalent to online gradient descent on the pinball loss). The step size γ trades adaptability against stability. Proposition 4.1 gives a distribution-free bound `|(1/T)Σ err_t − α| ≤ (max{α_1, 1−α_1} + γ)/(Tγ)`; Theorems 4.1–4.2 give tighter concentration and approximate marginal coverage under a hidden-Markov model with a fixed quantile function. Experiments: stock-volatility forecasting (GARCH(1,1) refit on the last 1250 days, normalized score, α = 0.1, γ = 0.005) and election-night county vote forecasting (conformalized quantile regression).

Results. The non-adaptive baseline (α fixed, calibration window refreshed each step) drifts far from the 90% target during regime changes such as the 2008 crisis and time-zone transitions in the election data; ACI keeps local coverage within the variation of an i.i.d. Bernoulli sequence. Coverage degrades markedly with an unnormalized conformity score, showing the method depends on the score being approximately stationary.

Weaknesses. The guarantee is for long-run average coverage only, not local or conditional coverage, and says nothing about interval width ($\alpha_t < 0$ yields infinite intervals and $\alpha_t > 1$ empty sets); no width results are reported. The finer theory is limited to a hidden-Markov model with a fixed quantile function. The method requires the label to be revealed at every step (delayed feedback is listed as open). Experiments cover only two domains with one α and one γ, and four of twelve stocks were shown because the baseline failed clearly. No comparison with other adaptive methods is given.

Use in our project. Method for RQ3. We report static split conformal, rolling-window split conformal and ACI on top of the rolling variant, with a pre-fixed normalized (or CQR) conformity score and $\alpha = 0.1$. For horizons of 5 and 15 minutes we run one ACI per horizon with delayed updates (not covered by the proven guarantee) and report empirical coverage, rolling local coverage, interval width, the α_t trajectory, and coverage separately on normal and ramp steps. We expect average coverage to approach 90% but coverage on ramp steps to stay lower, and will report this honestly.